

Guida Utente - SonarBun Live Translator

Traduttore live per audio da browser, desktop, microfono o device virtuali.

1. A cosa serve

SonarBun Live Translator ascolta una sorgente audio, trascrive il parlato con Whisper e, se configurato, traduce il testo tramite servizi online via API o tramite un modello locale offline. E' pensato per seguire live, VOD, video YouTube, streaming Twitch, meeting o contenuti in lingua straniera.

Il programma mostra il testo nella finestra principale e aggiorna un file live.txt con l'ultima traduzione, utile per overlay, OBS o altri strumenti.

2. Avvio dell'app

- 1 Aprire SonarBunLiveTranslator.exe.
- 2 Scegliere la sorgente audio: **Output** / **browser audio** oppure **Input** / **microphone**.
- 3 Scegliere il device audio corretto.
- 4 Impostare lingua sorgente e lingua destinazione.
- 5 In **Settings**, scegliere **Online** se si vuole usare un servizio online via API oppure **Offline** se si vuole usare un modello locale.
- 6 In modalita Online, configurare provider e API key. In modalita Offline, scaricare il modello locale dal pulsante dedicato.
- 7 Premere **Start**.

3. Live tab

Campo	Descrizione
Source	Sceglie se ascoltare un output di sistema/browser o un input fisico/virtuale.
Device	Device audio da ascoltare. Con Output vengono mostrati device loopback; con Input vengono mostrati microfoni e input virtuali.
Show all input APIs	Mostra tutti i backend audio disponibili. Di default l'app filtra la lista per mostrare solo MME e Windows WASAPI, che sono piu affidabili in questa app.
From	Lingua parlata nella sorgente audio. Impostare una lingua specifica, ad esempio Japanese o English, riduce errori di riconoscimento.
To	Lingua in cui tradurre.
Start / Stop	Avvia o ferma l'ascolto.

4. Input o Output?

Output / browser audio

Usare questa modalita per ascoltare audio proveniente da browser, YouTube, Twitch, player video o desktop. L'app usa il loopback WASAPI tramite PyAudioWPatch.

Se non arriva audio, provare un altro device output o controllare che Windows stia riproducendo il suono su quel dispositivo.

Input / microphone

Usare questa modalita per microfoni, interfacce audio o altri input virtuali. Di default la lista mostra MME e Windows WASAPI. DirectSound viene nascosto perche spesso viene enumerato ma puo non funzionare bene con questa pipeline.

5. Settings

Setting	A cosa serve
UI language	Cambia la lingua della GUI: English o Japanese. Non cambia la lingua tradotta.
Translation mode	Online usa un servizio online via API. Offline usa un modello locale scaricato nella cartella dell'app.
Translation provider	Sceglie il provider LLM da usare per la traduzione online.
Translation model	Modello usato per tradurre il testo trascritto.
API key	Chiave personale del provider scelto. Viene salvata cifrata con Windows DPAPI, non in chiaro.
Offline model	Modello locale da usare quando Translation mode e Offline. Al momento: NLLB-200 distilled 600M CT2 INT8.
Model status	Indica se il modello offline e gia installato. Se manca, il pulsante download e attivo.
Download model	Scarica il modello offline selezionato. Serve internet solo per il primo download.
Offline device	cpu o cuda per la traduzione offline.
Offline compute	Tipo di calcolo per il modello offline. Default consigliato: int8.
Glossary profile	Profilo glossario opzionale. None disattiva il glossario. Serve a gestire termini ricorrenti, nomi propri, slang, item e parole di contesto che non devono essere tradotte in modo troppo letterale.
Whisper model	Modello faster-whisper per la trascrizione. small e veloce; medium e piu accurato ma piu lento.
Whisper device	cpu o cuda. Se hai una GPU NVIDIA compatibile, cuda e consigliato.
Compute type	int8 per CPU; float16 per CUDA; float32 solo se necessario.
Beam size	Qualita vs velocita. Per live usare 1.
VAD mode	Aggressivita del rilevamento voce. 0 permissivo, 3 molto severo. Default consigliato: 2.
Max segment seconds	Durata massima di un blocco audio prima di trascrivere. Valori bassi riducono latenza ma possono tagliare frasi.
Silence tail ms	Tempo di silenzio usato per chiudere una frase. 250-350 ms e un buon punto di partenza.
Live output file	Nome del file aggiornato con l'ultima traduzione, di default live.txt.

6. Provider API

I provider indicati in questa sezione sono quelli attualmente supportati o usati come esempio. In futuro potranno essere aggiunti altri servizi online via API, se richiesto.

OpenAI

OpenAI e consigliato quando si vuole maggiore qualita di traduzione, specialmente con giapponese, contesto, slang, tono e frasi ambigue. Richiede una API key personale e consumo a pagamento secondo il proprio account.

Groq

Groq è molto interessante per traduzioni veloci e test a basso costo. Puoi accedere dalla console ufficiale: <https://console.groq.com/home>.

Groq offre accesso gratuito/rate-limited per iniziare e provare i modelli. È gratuito perché Groq mette a disposizione un piano di prova per sviluppatori, con limiti di utilizzo e rate limit; se superi i limiti, devi attendere il reset o passare a un piano superiore. I limiti possono cambiare, quindi controlla sempre console e pricing ufficiale.

Per ottenere una chiave Groq:

- 1 Vai su <https://console.groq.com/home>.
- 2 Accedi o crea un account.
- 3 Apri la sezione API Keys / Keys.
- 4 Crea una nuova API key.
- 5 Copia la chiave e incollala in SonarBun, selezionando provider **Groq**.
- 6 Premi **Save Settings** e poi **Test**.

Non condividere mai la tua API key. Se pensi che sia stata esposta, revocala dalla console del provider e creane una nuova.

7. Modalità offline

La modalità **Offline** permette di tradurre senza usare servizi API e senza connessione internet, tranne per scaricare il modello locale la prima volta. L'audio viene trascritto localmente con faster-whisper e la traduzione viene fatta con un modello locale NLLB in formato CTranslate2.

Al primo utilizzo bisogna scaricare il modello selezionato con **Download model**. Il modello attuale pesa circa 630 MB. Dopo il download, durante l'uso normale non vengono inviate frasi a servizi esterni.

La modalità offline è più privata, ma può essere meno naturale e meno contestuale rispetto ai servizi online via API. Su CPU può anche essere più lenta; con GPU NVIDIA e cuda può andare meglio.

8. Glossario e cache

Il menu **Glossary profile** permette di scegliere un profilo di termini. Il glossario serve a proteggere item, nomi propri, slang e termini di gioco che i modelli generici possono tradurre in modo troppo letterale.

In modalità **Online**, le voci rilevanti del glossario vengono inviate ai servizi online via API come istruzioni di supporto alla traduzione. In modalità **Offline**, NLLB non accetta istruzioni contestuali: il glossario viene quindi usato come correzione locale prima/dopo la traduzione.

Il file si trova in glossaries/glossary.json. Può essere mantenuto dall'utente seguendo lo stesso schema interno. Dopo la modifica, riavviare l'app per ricaricarlo.

SonarBun usa anche una cache locale in translation_cache.json: se la stessa frase viene tradotta di nuovo con lo stesso motore, lingue e glossario, viene riutilizzata la traduzione già salvata. Questo riduce latenza, chiamate API e variazioni tra traduzioni identiche.

9. File generati

File/cartella	Descrizione
live.txt	Contiene l'ultima traduzione. Viene sovrascritto a ogni frase utile.
history.txt	Storico della sessione con testo sorgente e traduzione.
sonarbun_config.json	Configurazione non sensibile: lingue, device, modello, provider, parametri audio.
models/	Cache dei modelli faster-whisper scaricati.

File/cartella	Descrizione
models/local_translation/	Cache dei modelli di traduzione offline scaricati dal pulsante Download model.
glossaries/glossary.json	Profili glossario modificabili.
translation_cache.json	Cache locale delle traduzioni già calcolate.
AppData/Local/SonarBunLiveTranslator/*.dpapi	API key cifrate con Windows DPAPI.

10. Setup CUDA su Windows

CUDA serve solo se vuoi usare la GPU NVIDIA per Whisper o per la traduzione offline. Se non sei sicuro, usa cpu + int8: è più lento, ma non richiede installazioni NVIDIA aggiuntive.

Per usare cuda servono: una GPU NVIDIA compatibile, driver NVIDIA aggiornati, e un ambiente CUDA/cuDNN funzionante. Il driver da solo può non bastare, perché alcune app cercano DLL come cuBLAS, CUDA runtime e cuDNN.

Installazione consigliata

- 1 Verifica di avere una GPU NVIDIA compatibile.
- 2 Installa o aggiorna il driver NVIDIA Game Ready o Studio dal sito NVIDIA.
- 3 Riavvia Windows.
- 4 Apri Prompt dei comandi e lancia nvidia-smi. Se mostra la GPU, il driver è attivo.
- 5 Se SonarBun con cuda non parte, installa CUDA Toolkit per Windows dalla pagina ufficiale NVIDIA.
- 6 Se l'errore cita cuDNN o DLL mancanti, installa cuDNN seguendo la guida ufficiale NVIDIA.
- 7 Riavvia Windows e riprova SonarBun con cuda + float16.

Nota: la versione indicata da nvidia-smi e la massima versione CUDA supportata dal driver, non necessariamente la versione del Toolkit installata.

Tabella risoluzione problemi CUDA

Situazione	Causa probabile	Soluzione
Non c'è GPU NVIDIA	PC con GPU Intel/AMD o solo integrata	Usare cpu e int8.
nvidia-smi non viene trovato	Driver NVIDIA mancante o PATH non aggiornato	Installare/aggiornare il driver NVIDIA e riavviare.
nvidia-smi funziona ma SonarBun fallisce su CUDA	Mancano runtime CUDA/cuBLAS/cuDNN richiesti da CTranslate2	Installare CUDA Toolkit e, se necessario, cuDNN.
Errore tipo cudnn o cublas DLL missing	DLL NVIDIA non trovate	Installare cuDNN/CUDA compatibili o assicurarsi che le cartelle bin siano nel PATH.
CUDA parte ma è instabile	Driver vecchio, VRAM insufficiente o modello troppo pesante	Aggiornare driver, usare modello Whisper più piccolo, o tornare a CPU/int8.
Utente non tecnico	Setup CUDA troppo complesso	Lasciare default cpu + int8.

11. Impostazioni consigliate

Veloce

Whisper small, cuda, float16, beam 1, max segment 2, silence tail 250-300, provider online veloce.

Bilanciato

Whisper medium, cuda, float16, beam 1, max segment 2-4, provider online secondo preferenza.

CPU

Whisper small o base, cpu, int8. La latenza sara maggiore.

Offline

Translation mode: Offline, modello NLLB-200 distilled 600M CT2 INT8, Offline compute: int8. Usare cuda se disponibile, altrimenti cpu.

12. Risoluzione problemi

Problema	Cosa provare
Non arriva audio	Cambiare device, verificare Output/Input, provare WASAPI o MME, controllare volume di Windows.
Traduzioni mancanti	Controllare API key, provider, connessione internet e history.txt.
Latenza alta	Usare modello Whisper piu piccolo, CUDA, beam 1, segmenti piu brevi, provider piu veloce.
Test API fallisce	Verificare che la chiave sia valida e che il provider abbia quota disponibile.
Download modello offline fallisce	Controllare la connessione e ripremere Download model. Il download puo riusare file gia scaricati.
Offline non traduce	Controllare che Model status sia Installed e che la coppia lingua sorgente/destinazione sia supportata.
Glossario non applicato	Verificare di aver selezionato il profilo in Settings e riavviare l'app dopo aver modificato glossary.json.
Traduzione vecchia o diversa da atteso	La cache puo riusare traduzioni gia salvate. Cancellare translation_cache.json se si vuole ripartire puliti dopo molte modifiche al glossario.
Traduzione strana	Impostare manualmente la lingua sorgente invece di Auto detect.

13. Fonti utili

- 1 Groq Console: <https://console.groq.com/home>
- 1 Groq Quickstart: <https://console.groq.com/docs/quickstart>
- 1 Groq Pricing: <https://groq.com/pricing>
- 1 NVIDIA CUDA Installation Guide for Windows:
<https://docs.nvidia.com/cuda/cuda-installation-guide-microsoft-windows/>
- 1 NVIDIA cuDNN Installation Guide: <https://docs.nvidia.com/deeplearning/cudnn/installation/latest/>
- 1 CTranslate2 GPU documentation: <https://opennmt.net/CTranslate2/installation.html>

Per qualsiasi dubbio, domanda o problema da risolvere, contattami direttamente. Account X: **@1pixeldot**.