

ユーザーガイド - SonarBun Live Translator

ブラウザ音声、デスクトップ音声、マイク、仮想オーディオデバイス向けのリアルタイム翻訳ツールです。

1. このアプリでできること

SonarBun Live Translator は、選択した音声ソースを聞き取り、Whisper で文字起こしし、設定に応じてオンライン API サービスまたはローカルのオフラインモデルで翻訳します。ライブ配信、VOD、YouTube、Twitch、会議、外国語コンテンツを見るときに使えます。

アプリ画面には元のテキストと翻訳結果が表示されます。また、最新の翻訳は live.txt に書き込まれるため、OBS のオーバーレイなどにも利用できます。

2. 起動方法

- 1 SonarBunLiveTranslator.exe を開きます。
- 2 音声ソースとして **出力 / ブラウザ音声** または **入力 / マイク** を選びます。
- 3 使用する音声デバイスを選びます。
- 4 元の言語と翻訳先の言語を選びます。
- 5 **設定** で、オンライン API サービスを使う場合は **オンライン**、ローカルモデルを使う場合は **オフライン** を選びます。
- 6 オンラインの場合はプロバイダーと API キーを設定します。オフラインの場合は専用ボタンでローカルモデルをダウンロードします。
- 7 **開始** を押します。

3. ライブ画面

項目	説明
音声ソース	PC/ブラウザの出力音声を聞くか、マイクなどの入力を聞くかを選びます。
デバイス	聞き取る音声デバイスです。出力モードではループバックデバイス、入力モードではマイクや仮想入力が表示されます。
すべての入力APIを表示	Windows が認識しているすべての音声バックエンドを表示します。通常は MME と Windows WASAPI のみ表示されます。この2つがこのアプリでは比較的安定しています。
元の言語	話されている言語です。Japanese や English のように明示すると認識ミスが減ります。
翻訳先	翻訳する先の言語です。
開始 / 停止	音声の聞き取りを開始または停止します。

4. 入力と出力の違い

出力 / ブラウザ音声

ブラウザ、YouTube、Twitch、動画プレイヤー、デスクトップ音声を翻訳したい場合に使います。アプリは PyAudioWPatch を使い、WASAPI ループバックで音声を取得します。

入力 / マイク

マイク、オーディオインターフェース、その他の仮想入力を使う場合はこちらを選びます。通常の一覧では MME と Windows WASAPI だけを表示します。DirectSound は Windows 上では表示されることがありますが、このアプリでは安定しない場合があるため通常は非表示です。

5. 設定画面

設定	説明
表示言語	GUI の表示言語を English または 日本語に変更します。翻訳の言語設定とは別です。
翻訳モード	オンライン はオンライン API サービスを使います。オフライン はアプリ内に保存されたローカルモデルを使います。
翻訳プロバイダー	オンライン翻訳に使う LLM プロバイダーを選びます。
翻訳モデル	文字起こし結果を翻訳するモデルです。
APIキー	選択したプロバイダーの個人用 API キーです。Windows DPAPI で暗号化され、平文では保存されません。
オフラインモデル	翻訳モードがオフラインのときに使うローカルモデルです。現在は NLLB-200 distilled 600M CT2 INT8 が選べます。
モデル状態	オフラインモデルがインストール済みかどうかを表示します。未インストールの場合はダウンロードボタンが有効になります。
モデルをダウンロード	選択したオフラインモデルをダウンロードします。初回ダウンロード時のみインターネットが必要です。
オフラインデバイス	オフライン翻訳に使う cpu または cuda です。
オフライン計算	オフラインモデルの計算タイプです。推奨デフォルトは int8 です。
用語集プロファイル	任意の用語集です。None で無効化します。繰り返し出る用語、固有名詞、スラング、アイテム名、文脈固有の単語が直訳されすぎるのを抑えるために使います。
Whisperモデル	文字起こしに使う faster-whisper モデルです。small は高速、medium は精度が高めですが遅くなります。
Whisperデバイス	cpu または cuda。対応 NVIDIA GPU がある場合は cuda 推奨です。
計算タイプ	CPU なら int8、CUDA なら float16 推奨です。
ビームサイズ	品質と速度の調整です。リアルタイム用途では 1 推奨です。
VADモード	音声検出の強さです。0 はゆるく、3 は厳しくなります。推奨値は 2 です。
最大セグメント秒数	文字起こしに送る音声ブロックの最大秒数です。短いほど遅延は減りますが、文が途中で切れることがあります。
無音判定 ms	どれくらい無音が続いたら文を区切るかです。250-350 ms から始めるのがおすすめです。
ライブ出力ファイル	最新の翻訳を書き込むファイルです。デフォルトは live.txt です。

6. API プロバイダー

このセクションのプロバイダーは、現在対応しているもの、または実用例として記載しているものです。必要に応じて、将来的に他のオンライン API サービスが追加される可能性があります。

OpenAI

日本語、文脈、スラング、ニュアンス、あいまいな文の翻訳品質を重視する場合は OpenAI がおすすめです。個人用 API キーが必要で、利用量に応じて課金されます。

Groq

Groq は高速で、低コストまたは無料枠で試しやすいプロバイダーです。公式コンソールはこちらです:
<https://console.groq.com/home>

Groq には開発者向けの無料アクセス/無料枠があります。ただし、無料で使えるのは利用制限やレート制限があるためです。上限を超えた場合はリセットを待つか、有料/Developer プランに切り替える必要があります。制限は変更される可能性があるため、必ず公式コンソールと料金ページを確認してください。

Groq の API キーを取得する手順:

- 1 `https://console.groq.com/home` を開きます。
- 2 ログイン、またはアカウントを作成します。
- 3 API Keys / Keys のページを開きます。
- 4 新しい API キーを作成します。
- 5 SonarBun でプロバイダーを **Groq** にして、キーを貼り付けます。
- 6 **設定を保存** を押し、その後 **テスト** を押します。

API キーは他人に共有しないでください。漏れた可能性がある場合は、プロバイダーのコンソールで無効化し、新しいキーを作成してください。

7. オフラインモード

オフライン モードでは、API サービスを使わず、初回のローカルモデルのダウンロード時を除いてインターネット接続なしで翻訳します。音声は `faster-whisper` でローカル文字起こしされ、その後 `CTranslate2` 形式のローカル `NLLB` モデルで翻訳されます。

初回のみ、**モデルをダウンロード** で選択したモデルを取得する必要があります。現在のモデルは約 630 MB です。ダウンロード後、通常のオフライン翻訳では文章を外部サービスに送信しません。

オフラインモードはプライバシー面で有利ですが、オンライン API サービスより自然さや文脈理解が弱い場合があります。CPU では遅くなることがあり、NVIDIA GPU と `cuda` を使うと改善する場合があります。

8. 用語集とキャッシュ

用語集プロファイル では、任意の用語集を選べます。アイテム名、固有名詞、スラング、ゲーム固有の用語が不自然に直訳されるのを減らすための機能です。

オンライン モードでは、関連する用語がオンライン API サービスへ翻訳補助の指示として送信されます。**オフライン** モードでは `NLLB` が文脈指示を受け取れないため、翻訳前後のローカル補正として使われます。

用語集ファイルは `glossaries/glossary.json` です。ユーザーは同じ内部スキーマに従ってメンテナンスできます。編集後はアプリを再起動してください。

SonarBun は `translation_cache.json` に翻訳キャッシュも保存します。同じ文章が同じエンジン、言語、用語集で再度翻訳される場合、保存済みの翻訳を再利用します。これにより遅延、API 呼び出し、同一文の翻訳ゆれを減らせます。

9. 生成されるファイル

ファイル/フォルダ	説明
<code>live.txt</code>	最新の翻訳が入ります。新しい文が処理されるたびに上書きされます。
<code>history.txt</code>	元のテキストと翻訳結果の履歴です。
<code>sonarbun_config.json</code>	言語、デバイス、モデル、プロバイダー、音声パラメータなどの設定です。API キーは入りません。
<code>models/</code>	ダウンロードされた <code>faster-whisper</code> モデルのキャッシュです。
<code>models/local_translation/</code>	モデルをダウンロードボタンで取得したオフライン翻訳モデルのキャッシュです。
<code>glossaries/glossary.json</code>	編集可能な用語集プロファイルです。

ファイル/フォルダ	説明
translation_cache.json	過去に計算した翻訳のローカルキャッシュです。
AppData/Local/SonarBunLiveTranslator/*.dpapi	Windows DPAPI で暗号化された API キーです。

10. Windows での CUDA セットアップ

CUDA は、Whisper またはオフライン翻訳で NVIDIA GPU を使いたい場合だけが必要です。よく分からない場合は cpu + int8 を使ってください。速度は落ちますが、追加の NVIDIA セットアップは不要です。

cuda を使うには、対応 NVIDIA GPU、最新の NVIDIA ドライバー、正常に動作する CUDA/cuDNN 環境が必要です。ドライバだけでは不十分な場合があります。cuBLAS、CUDA runtime、cuDNN などの DLL が必要になることがあるためです。

推奨インストール手順

- 1 PC に対応 NVIDIA GPU があるか確認します。
- 2 その GPU 用の公式 NVIDIA ドライバーをインストール、または更新します。
- 3 Windows を再起動します。
- 4 コマンドプロンプトを開き、nvidia-smi を実行します。GPU が表示されればドライバは有効です。
- 5 SonarBun で cuda 使用時に失敗する場合は、NVIDIA 公式ページから Windows 用 CUDA Toolkit をインストールします。
- 6 エラーに cuDNN や DLL missing が出る場合は、NVIDIA 公式ガイドに従って cuDNN をインストールします。
- 7 Windows を再起動し、SonarBun で cuda + float16 を再度試します。

注意: nvidia-smi に表示される CUDA バージョンは、ドライバが対応できる最大 CUDA バージョンです。インストール済み Toolkit のバージョンとは限りません。

CUDA トラブルシューティング表

状況	考えられる原因	対処
NVIDIA GPU がない	Intel/AMD GPU または内蔵 GPU のみ	cpu と int8 を使います。
nvidia-smi が見つからない	NVIDIA ドライバー未インストール、または PATH 未更新	NVIDIA ドライバーをインストール/更新し、再起動します。
nvidia-smi は動くが SonarBun の CUDA が失敗する	CTranslate2 が必要とする CUDA/cuBLAS/cuDNN runtime が不足	CUDA Toolkit をインストールし、必要なら cuDNN も入れます。
cudnn や cublas DLL missing エラー	NVIDIA DLL が見つからない	互換性のある cuDNN/CUDA を入れるか、bin フォルダが PATH に入っているか確認します。
CUDA は起動するが不安定	古いドライバ、VRAM 不足、モデルが重い	ドライバ更新、小さい Whisper モデル、または CPU/int8 に戻します。
PC に詳しくないユーザー	CUDA セットアップが複雑	デフォルトの cpu + int8 のまま使います。

11. おすすめ設定

高速

Whisper small、cuda、float16、beam 1、max segment 2、silence tail 250-300、高速なオンラインプロバイダー。

バランス

Whisper medium、cuda、float16、beam 1、max segment 2-4、任意のオンラインプロバイダー。

CPU の場合

Whisper small または base、cpu、int8。遅延は大きくなります。

オフライン

翻訳モード: オフライン、モデル NLLB-200 distilled 600M CT2 INT8、オフライン計算: int8。利用可能なら cuda、なければ cpu を使います。

12. トラブルシューティング

問題	試すこと
音声が入らない	デバイスを変える、Output/Input を確認する、WASAPI または MME を試す、Windows の音量を確認する。
翻訳が出ない	API キー、プロバイダー、インターネット接続、history.txt を確認する。
遅延が大きい	小さい Whisper モデル、CUDA、beam 1、短いセグメント、高速なプロバイダーを使う。
API テストに失敗する	キーが正しいか、プロバイダーの利用枠が残っているか確認する。
オフラインモデルのダウンロードに失敗する	接続を確認し、もう一度 モデルをダウンロード を押します。途中で取得したファイルを再利用できる場合があります。
オフラインで翻訳されない	モデル状態がインストール済みになっているか、選択した言語ペアが対応しているか確認します。
用語集が反映されない	設定画面でプロファイルを選択しているか確認してください。glossary.json を編集した後はアプリを再起動します。
古い翻訳や期待と違う翻訳が出る	キャッシュが保存済み翻訳を再利用している可能性があります。用語集を大きく変更した後は translation_cache.json を削除するとリセットできます。
翻訳がおかしい	Auto detect ではなく、元の言語を手動で指定する。

13. 便利なリンク

- 1 Groq Console: <https://console.groq.com/home>
- 1 Groq Quickstart: <https://console.groq.com/docs/quickstart>
- 1 Groq Pricing: <https://groq.com/pricing>
- 1 NVIDIA CUDA Installation Guide for Windows: <https://docs.nvidia.com/cuda/cuda-installation-guide-microsoft-windows/>
- 1 NVIDIA cuDNN Installation Guide: <https://docs.nvidia.com/deeplearning/cudnn/installation/latest/>
- 1 CTranslate2 GPU documentation: <https://opennmt.net/CTranslate2/installation.html>

疑問、質問、解決したい問題がある場合は、直接連絡してください。X アカウント: **@1pixeldot**.